



Universidad  
de Concepción

# Modelo de Variable Dependiente Discreta

## Modelos de datos contables

---

Felipe J. Quezada-Escalona  
Departamento de Economía

- **Regresión de Poisson**

- Modelo de regresión para **datos de conteo**, donde la variable dependiente representa el **número de eventos en un tiempo** o espacio específico.
- Los datos de conteo son no negativos y discretos (0, 1, 2,...).

- Ejemplos:

- Número de cervezas que se venden en un bar entre las 23:00 y las 00:00 horas.
- Número de accidentes de tráfico en una intersección por día.
- Número de llamadas telefónicas recibidas por un centro de atención al cliente por minuto.

El modelo de probabilidad esta dado por:

- **Función de Probabilidad:**

$$P(Y = y) = \frac{e^{-\lambda} \lambda^y}{y!}, \quad y = 0, 1, 2, \dots$$

donde  $Y$  es variable discreta que representa el número de eventos;  $\lambda$  es la **media**.

Para estimar un modelo poisson:

- **Relación entre Media y Variables Independientes:** Generalmente uno asume que

$$\lambda = E(Y|X) = e^{X'\beta}$$

donde  $X = (X_1, X_2, \dots, X_k)'$  es un vector de variables explicativas.

- Es decir, el modelo de Poisson es log-lineal  $\ln(\lambda_i) = \beta' \mathbf{X}$
- **Supuesto Clave:**  $Y$  sigue una distribución de Poisson con media  $\lambda$ , donde  $\lambda$  es función de  $X$ . Es decir,  $Y \sim \text{Poisson}(\lambda(X))$

En Poisson log-lineal  $\ln(\lambda_i) = \beta' \mathbf{X}$ :

- **Coeficientes ( $\beta_j$ ):**
  - Representan el cambio en el logaritmo de la media de  $Y$  por un cambio de una unidad en  $X_j$ , manteniendo constantes las demás variables.
  - $\exp(\beta_j)$  representa el cambio multiplicativo en la media de  $Y$  con un cambio unitario en  $X_j$ .
- **Ejemplo:** Si  $\exp(\beta_1) = 1,2$ , un aumento de una unidad en  $X_1$  se asocia con un aumento del 20% en la media de  $Y$ .

Considerando la función de probabilidad, la verosimilitud es:

$$L(\beta) = \prod_{i=1}^n \frac{e^{-\lambda_i} \lambda_i^{y_i}}{y_i!}$$

donde  $\lambda_i = e^{X_i' \beta}$ .

y la **Log-Verosimilitud** es:

$$\ell(\beta) = \sum_{i=1}^n (y_i X_i' \beta - e^{X_i' \beta} - \ln(y_i!))$$

- Los **Errores Estándar** se calculan a partir de la matriz de información de Fisher.
- Y las **Pruebas de Hipótesis** se pueden realizar mediante pruebas t para la significancia individual de los coeficientes y pruebas de Wald para restricciones conjuntas.
- Respecto a los **Intervalos de Confianza**, se pueden construir intervalos de confianza para los coeficientes de forma usual.

La sobredispersión ocurre cuando la varianza de  $Y$  es mayor que su media, violando el supuesto de Poisson (**equidispersión**).

- **Causas:**

- Heterogeneidad no observada.
- Omisión de variables relevantes.
- Eventos correlacionados.

- **Consecuencias:**

- Sesgo en estimaciones de errores estándar.
- Pruebas de hipótesis incorrectas.



## Soluciones:


- **Regresión Binomial Negativa:** Modelo alternativo para permitir sobredispersión.
  - En este caso la varianza es  $Var(y_i) = \mu + \alpha\mu_i^p$ , donde  $p = 1, 2$  (Tipo 1  $p = 1$ , y en Tipo 2 es  $p = 2$ )
  - $\alpha$  es el parametro que mide la dispersión.
- **Estimación Robusta:** Ajuste de errores estándar para sobredispersión.

Tenemos diez puntos de datos de una distribución Poisson, pero ¿cuál es el parámetro  $\lambda$  de la distribución?


$$y = 2, 0, 1, 2, 2, 2, 0, 2, 1, 1$$

$$f(y \mid \lambda) = \frac{e^{-\lambda} \lambda^y}{y!}$$


$$\lambda = 1$$



$$\lambda = 3$$



$$\lambda = 5$$



Tenemos diez puntos de datos de una distribución Poisson, pero ¿cuál es el parámetro  $\lambda$  de la distribución?

$$\mathbf{y} = \{2, 0, 1, 2, 2, 2, 0, 2, 1, 1\}$$

$$L(\lambda \mid \mathbf{y}) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{y_i}}{y_i!} = \frac{e^{-n\lambda} \lambda^{\sum_{i=1}^n y_i}}{\prod_{i=1}^n y_i!}$$

$$\ln L(\lambda \mid \mathbf{y}) = -n\lambda + \ln \lambda \sum_{i=1}^n y_i - \sum_{i=1}^n \ln(y_i!)$$

$$\frac{\partial \ln L(\lambda \mid \mathbf{y})}{\partial \lambda} = -n + \frac{1}{\lambda} \sum_{i=1}^n y_i$$

$$\frac{\partial \ln L(\lambda \mid \mathbf{y})}{\partial \lambda} = 0 \Rightarrow \hat{\lambda} = \frac{1}{n} \sum_{i=1}^n y_i = 1.3$$

Tenemos diez puntos de datos de una distribución Poisson, pero ¿cuál es el parámetro  $\lambda$  de la distribución?


$$\mathbf{y} = \{2, 0, 1, 2, 2, 2, 0, 2, 1, 1\}$$

$$L(\lambda \mid \mathbf{y}) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{y_i}}{y_i!} = \frac{e^{-n\lambda} \lambda^{\sum_{i=1}^n y_i}}{\prod_{i=1}^n y_i!} = \frac{e^{-10\lambda} \lambda^{13}}{32}$$

$$\ln L(\lambda \mid \mathbf{y}) = -n\lambda + \ln \lambda \sum_{i=1}^n y_i - \sum_{i=1}^n \ln(y_i!) = -10\lambda + 13 \ln \lambda - 3.47$$

- Stata: `rpoisson`
- R: `glm`

```
# 1. Datos a usar
set.seed(123)
n      <- 1000
x      <- rnorm(n, mean = 0, sd = 1)
b0     <- 1
b1     <- 0.5
lambda <- exp(b0 + b1 * x)
y      <- rpois(n, lambda)      # (ej., número crímenes)
```



```
library(maxLik)
```

```
ch_ll<- function(params) {
```

```
  b0 <- params[1]
```

```
  b1 <- params[2]
```

```
  xb <- b0 + b1 * x
```

```
  mu <- exp(xb)
```

```
  ll <- -mu + y * xb - lfactorial(y)
```

```
  return(sum(ll))
```

```
}
```

```
mle_poisson <- maxLik(logLik=ch_ll, start=c(0.1, 0.1))
```

```
summary(mle_poisson)
```



```
## -----  
## Maximum Likelihood estimation  
## Newton-Raphson maximisation, 4 iterations  
## Return code 8: successive function values within relative tolerance limit (re  
## Log-Likelihood: -1889.833  
## 2 free parameters  
## Estimates:  
##      Estimate Std. error t value Pr(> t)  
## [1,]  1.00000    0.02012  49.71  <2e-16 ***  
## [2,]  0.47950    0.01802  26.61  <2e-16 ***  
## ---  
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1  
## -----
```

```
glm(y ~ x, family = poisson(link = "log"))
```

```
##  
## Call:  glm(formula = y ~ x, family = poisson(link = "log"))  
##  
## Coefficients:  
## (Intercept)          x  
##      1.0000      0.4795  
##  
## Degrees of Freedom: 999 Total (i.e. Null);  998 Residual  
## Null Deviance:      1845  
## Residual Deviance: 1140    AIC: 3784
```

# ¡Muchas gracias!

Felipe J. Quezada-Escalona

Department of Economics



¿Preguntas?